

Bankkártyás csalások detektálása statisztikai modellel

Készítette: Princzinger Krisztián, 2026

Tartalomjegyzék

1. Bevezetés – A bankkártyás csalások anatómiája.....	2
1.1. A probléma üzleti és számviteli jelentősége	2
1.2. A vizsgált adathalmaz bemutatása.....	2
1.3. A kutatási cél és az elemzés módszertana.....	3
2. Követelményspecifikáció, informatikai megoldás	4
3. Megvalósíthatósági tanulmány	5
3.1. A statisztikai zaj problémája	5
3.2. Megoldás a zajra: alul-mintavételezés	5
3.3. Változók standardizálása, a torzítások kiküszöbölésére.....	6
4. Logikai és fizikai rendszerterv	7
4.1. Input – Process – Output (IPO) diagram	7
4.2. Jackson-ábrák.....	7
4.2.1. Szekvencia – A teljes folyamat	7
4.2.2. Szelekció – Döntési logika	7
4.2.3. Iteráció – Tömeges feldolgozás.....	8
5. A megvalósítás és az alkalmazott algoritmusok	9
6. Eredmények összefoglalása és üzleti értékelés.....	11
7. Irodalomjegyzék	13
7.1. Publikációk:	13
7.2. Internetes cikkek:	13
7.3. Datasets:	13

1. Bevezetés – A bankkártyás csalások anatómiája

1.1. A probléma üzleti és számviteli jelentősége

A digitális tranzakciók robbanásszerű növekedésével a bankkártyás csalások (fraud) globális iparaggá nőttek ki magukat. Egy pénzügyi intézet számára a csalások nem csupán közvetlen számviteli veszteséget (leírt követeléseket, kártérítéseket) jelentenek, hanem ami ennél is súlyosabb: a bizalmi tőke erózióját. A hagyományos, szabályalapú belső ellenőrzési és kockázatkezelési rendszerek mára elérték korlátaikat. A másodpercenként beérkező több ezer tranzakció manuális ellenőrzése lehetetlen, a merev limitrendszerek pedig vagy túl sok téves riasztást generálnak, vagy túlságosan sebezhetők.

A Nilson Report iparági elemzése szerint a globális bankkártyás csalásokból eredő kár évente több tízmilliárd dollárra tehető, és ez az összeg az e-kereskedelem dominanciájával folyamatosan növekszik. (Globe Newswire, 2025)

A pénzügyi intézetek hagyományosan statikus szabályrendszereket (rule-based systems) alkalmaztak a védekezésre, például földrajzi korlátozásokat (ha egy magyar kártyát hirtelen Indonéziában használnak) vagy összegbeli limiteket. (Palanisamy, 2025)

Ezek a rendszerek azonban rendkívül merevek, és a modern kiberbűnözők könnyedén kijátsszák őket azáltal, hogy a tranzakciókat a normál ügyféli viselkedéshez hasonlóvá maszkírozzák.

Ebben a kihívásokkal teli környezetben találkozunk az informatika és a pénzügy. A gépi tanulás (Machine Learning) és a prediktív analitika lehetővé teszi a bankok számára, hogy proaktív módon, valós időben szűrjék ki a gyanús mintázatokat, minimalizálva a pénzügyi veszteséget, miközben fenntartják az ügyfélélményt. Jelen esszé egy ilyen analitikai folyamatot dokumentál a nyers adatok feldolgozásától a vezetői döntéstámogatásig.

1.2. A vizsgált adathalmaz bemutatása

Az elemzéshez a Kaggle platformról származó, európai kártyabirtokosok tranzakcióit tartalmazó nyílt adatbázist, egy úgynevezett Credit Card Fraud Detection dataset-et használtam. Az adatsor két nap (48 óra) banki forgalmát rögzíti, összesen 284 807 tranzakciót.

Az adatbázis a banktitok és a GDPR szabályozások miatt az ügyfelek személyes adatai és a kártyaadatok nem ismertek. Az adatbázis 28 darab úgynevezett Főkomponens (V1-től V28-ig tartó numerikus változó) oszlopot tartalmaz. Ezek egy Főkomponens-analízis (PCA) matematikai transzformáció eredményei, amelyek megőrzik az eredeti adatok statisztikai

tulajdonságait, de visszafejthetetlenek. Csak két változó maradt eredeti formájában: a Time (a tranzakciók között eltelt másodpercek száma az első tranzakciótól számítva) és az Amount (a tranzakció összege euróban). Ezen kívül megtalálható még egy bináris indikátor, ahol a 0 a legális, az 1 pedig a bizonyítottan csalárd tranzakciót jelöli.

1.3. A kutatási cél és az elemzés módszertana

Az elemzés fő célja egy olyan statisztikai osztályozó modell - Logisztikus Regresszió - felépítése a SAS OnDemand for Academics szoftver segítségével, amely képes felismerni a csalásokat. A projekt legnagyobb módszertani kihívása az adatok szélsőséges kiegyensúlyozatlansága: a bináris indikátor vizsgálata során lefuttatott alapvető statisztikák számszerűen is megerősítették a probléma súlyát és a feladat nehézségét: kiderül, hogy a közel 285 ezer tranzakcióból mindössze 492 eset (0,17%) volt tényleges csalás.

Az esszé a továbbiakban bemutatja az adattisztítás és skálázás folyamatát, a mintavételezési technikákat (Under-sampling), a prediktív modell felépítését, végül pedig a kapott konfúziós mátrix számviteli és üzleti értelmezését.

Az átlagos tranzakciós összegek elemzése szintén beszédes mintázatot mutatott. Míg a normál vásárlások átlagos értéke viszonylag alacsonyabb volt, addig a csalók átlagosan valamivel magasabb összegekkel próbálkoztak, ugyanakkor gondosan kerültek a rendkívül kiugró, több tízezer eurós tételeket. Ez a viselkedés feltételezhetően tudatos: a bűnözők igyekeznek a radar alatt maradni, hogy elkerüljék a banki rendszerek azonnali, automatikus limit-blokkolását.

2. Követelményspecifikáció, informatikai megoldás

A kutatás és a felépítendő informatikai megoldás elsődleges célja egy olyan valós idejű, prediktív döntéstámogató rendszer kialakítása, amely képes a tranzakciók másodperc alapú, automatikus minősítésére. A rendszerrel szemben támasztott alapvető üzleti és informatikai követelmény, hogy a matematikai modell a lehető legmagasabb pontossággal szűrje ki a valódi csalásokat, miközben a téves riasztások számát a minimálisra csökkenti. A tévesen megvádolt, és ezáltal a fizetésben megakadályozott becsületes ügyfelek arányának alacsonyan tartása kiemelt üzleti prioritás, hiszen egy túlságosan szigorúra kalibrált rendszer súlyos ügyfél-elégedetlenségi és reputációs kockázatot hordoz a bank számára. Ennek megfelelően a modell minőségét és sikerességét nem az általános statisztikai pontosság határozza meg, hanem a megfogott csalók aránya és a precizitás (a téves riasztások aránya) kényes egyensúlya. Az informatikai megvalósítás során továbbá célszerű a SAS szoftverkörnyezet használata, amely robusztus adatkezelési képességeivel képes megbirkózni a nagyméretű, iparági standardoknak megfelelő adatállományokkal.

Bár a Microsoft Excel elméletileg képes ekkora sorállomány kezelésére, a gyakorlatban a közel 285 000 rekord és a hozzájuk tartozó 31 változó egyidejű, komplex statisztikai számítása, az adatok skálázása és a prediktív modellezés már olyan mértékű memória- és processzorigényt generálna, amely jelentős feldolgozási idővel, illetve rendszerstabilitási kockázatokkal járna. Ezzel szemben a SAS robusztus, professzionális architektúrája és kódalapú feldolgozási logikája lehetővé teszi a nagyméretű, iparági standardoknak megfelelő adatállományok hatékony, biztonságos és gyors elemzését. Ráadásul a *SAS OnDemand for Academics* verzió egy felhőalapú megoldás, ami azt jelenti, hogy a számításigényes algoritmusok futtatása nem a lokális számítógépet terheli, hanem a SAS Institute nagyteljesítményű szervereit veszi igénybe. Ez az architektúra kutatási és egyetemi esszéírási célokra különösen ideálissá teszi a platformot, hiszen lényegében zero helyi hardverigény mellett teszi lehetővé a komplex Big Data elemzések elvégzését.

3. Megvalósíthatósági tanulmány

3.1. A statisztikai zaj problémája

A feladat sikeres megoldásához elengedhetetlen a megfelelő adatelőkészítési és modellezési módszertanok kiválasztása, mivel a vizsgált adathalmaz egy klasszikus, úgynevezett ritka eseményekből álló statisztikai problémát reprezentál. A hagyományos gépi tanulási algoritmusok jellemzően rendkívül gyengén teljesítenek olyan esetekben, ahol a célváltozó osztályai között extrém aránytalanság figyelhető meg. (Krawczyk, 2016)

Ha a logisztikus regressziós modell betanítása közvetlenül az eredeti, kilencvenkilenc százalékban legális tranzakciókat tartalmazó adathalmazon történne, az algoritmus pusztán a többségi osztály jellemzőit tanulná meg, a ritka, de kritikus csalási kísérleteket pedig egyszerű statisztikai zajként kezelné, és figyelmen kívül hagyná. Ezt a jelenséget a szakirodalom pontossági paradoxonnak nevezi. Mivel az adatbázisban a csalások aránya mindössze 0,17 százalék, egy olyan naiv algoritmus, amely minden egyes tranzakcióra azt a jóslatot adja, hogy az legális, 99,83 százalékos általános pontosságot érne el. Bár ez a mérőszám papíron kiválónak tűnik, a modell üzleti értéke nulla lenne, hiszen éppen a kiszűrendő bűncselekményeket nem találná meg.

Az ilyen extrém módon aszimmetrikus adathalmazoknál a hagyományos modellek kizárólag a többségi osztályra optimalizálnak, így a pusztán statisztikai pontosság (accuracy) mint értékelési metrika rendkívül megtévesztő. Ennek okán a megvalósíthatóság elsődleges feltétele az adatok előzetes, mesterséges transzformációja. (Chawla et al., 2004)

3.2. Megoldás a zajra: alul-mintavételezés

A probléma kiküszöbölésére az elemzés adatkezelési fázisában az alul-mintavételezés (under-sampling) technikájának alkalmazása a leginkább célravezető megoldás. Ennek a lépésnek a lényege, hogy a többségi, legális tranzakciókból egy véletlenszám-generátor segítségével kiválasztunk pontosan annyi megfigyelést, amennyi a kisebbségi osztályban, azaz a csalások között szerepel. Ezzel a módszertani lépéssel egy mesterségesen kiegyensúlyozott, ötven-ötven százalékos arányú tanító adathalmaz jön létre. Ez az új, kiegyensúlyozott struktúra már lehetővé teszi a prediktív algoritmus számára, hogy fókuszáltan a csalókra jellemző rejtett dimenziókat és mintázatokat azonosítsa, anélkül, hogy a hatalmas mennyiségű legális adat elnyomná ezeket a finom jelzéseket. (Batista et al., 2004.)

A szakirodalom gyakran hivatkozik egy alternatív megoldásra, a szintetikus kisebbségi túlmintavételezési technikára (SMOTE - Synthetic Minority Over-sampling Technique), amely nem eldobja a legális tranzakciókat, hanem a csalásokból generál mesterséges új adatpontokat. (Chawla et al., 2002)

Jelen kutatás esetében azonban az alul-mintavételezés alkalmazása technológiai és erőforrás-menedzsment szempontból is indokoltabb volt. A kiinduló adatbázis közel háromezer sort tartalmaz; a túlmintavételezés ezt az állományt drasztikusan, akár félmillió rekord fölé növelte volna, ami jelentős és felesleges feldolgozási időt (processing time) igényelt volna a SAS szoftverben. Az alul-mintavételezéssel kapott kompaktabb, zajmentesített tanító adathalmaz hatékonyabb futtatást és tisztább modellépítést tett lehetővé.


3.3. Változók standardizálása, a torzítások kiküszöbölésére

A mintavételezési eljárást megelőzően egy másik kritikus adattisztítási lépés, a változók skálázásának elvégzése is elengedhetetlen a megvalósíthatóság szempontjából. Mivel az eredeti pénzügyi adatokat tartalmazó *Amount* változó értékei nagyságrendekkel eltérnek a titkosított, már előzetesen transzformált főkomponensek (*V1-V28*) alacsony, tizedestört értékeitől, az összeg oszlopot standardizálni kell. Ezen transzformáció nélkül az algoritmus számítási mechanizmusa tévesen nagyobb súlyt rendelne a magasabb nominális értékkel (nagyobb számokkal) rendelkező változóhoz. Ha a változók nincsenek közös skálán, a modell betanítása indokolatlanul sok időt vesz igénybe, és a végső előrejelzés statisztikailag torzított lesz. A standardizálás biztosítja, hogy a matematikai modell minden dimenziót egyenlő eséllyel és azonos súllyal tudjon vizsgálni az optimalizáció során. (Géron, 2019.)

4. Logikai és fizikai rendszerterv

4.1. Input – Process – Output (IPO) diagram


Az IPO diagram a rendszer adatforgalmi alapvázát mutatja be, elkülönítve az erőforrásokat a műveletektől. A bemeneti rétegben (Input) a nyers, 284 807 rekordból álló .csv állomány és a tranzakciós változók szerepelnek. A feldolgozási szakaszban (Process) a SAS szoftver végzi el az adattisztítást, a Z-score standardizálást és a logisztikus regressziós elemzést. A kimeneti réteg (Output) pedig a már minősített tranzakciókat, a valószínűségi pontszámokat és a statisztikai konfúziós mátrixot szolgáltatja a döntéshozók számára.



4.2. Jackson-ábrák

4.2.1. Szekvencia – A teljes folyamat


A szekvencia diagram a szoftveres megvalósítás lineáris, egymásra épülő fázisait szemlélteti. A folyamat merev sorrendet követ: az adatok beolvasásától a változók standardizálásán és a mintavételezésen keresztül vezet az út a modell betanításáig.



4.2.2. Szelekció – Döntési logika

A szelekciós ábra a modell bináris döntési logikáját modellezi. Minden egyes tranzakció kiértékelésekor a rendszer egy logikai válaszúthoz érkezik: a prediktív algoritmus által

számított valószínűség alapján a tranzakció vagy a 'legális', vagy a 'csalárd' (fraud) osztályba sorolódik.



4.2.3. Iteráció – Tömeges feldolgozás

Az iterációs diagram a rendszer nagy mennyiségű adat feldolgozására vonatkozó ciklikus algoritmusát mutatja be. Mivel a banki állomány több százezer rekordot tartalmaz, a SAS szoftver egy iteratív hurok keretében minden egyes soron (tranzakción) elvégzi ugyanazt a kiértékelő műveletet. Ez az ismétlődő struktúra garantálja a teljes körű ellenőrzést, biztosítva, hogy egyetlen tranzakció se maradjon ellenőrizetlenül a teljes adatbázisban.



5. A megvalósítás és az alkalmazott algoritmusok

A gyakorlati megvalósítás során az első lépés a nyers, pontosvesszővel tagolt, szöveges formátumú .csv adatállomány beolvasása volt a SAS OnDemand for Academics felhőalapú környezetébe. A .csv fájlban minden sor egy rekordot, és minden pontosvessző egy tulajdonságot jelent. A beolvasást a SAS beépített importáló eljárásával hajtottam végre. A rendszer automatikusan felismerte a változók neveit és típusait, majd létrehozta a szerver munkakönyvtárában az elemzésre kész kiinduló táblát.

```
%web_drop_table(WORK.IMPORT);
```

```
FILENAME REFFILE '/home/u64472364/Card Fraud Essay/creditcard.csv';
```

```
PROC IMPORT DATAFILE=REFFILE
```

```
    DBMS=CSV
```

```
    OUT=WORK.IMPORT;
```

```
    GETNAMES=YES;
```

```
RUN;
```

```
PROC CONTENTS DATA=WORK.IMPORT; RUN;
```

```
%web_open_table(WORK.IMPORT);
```

Az adatok sikeres betöltését és a feltárási statisztikák lefuttatását követően a modellépítés előfeltételeként elvégeztem a változók skálázását. Ahogy a megvalósíthatósági tanulmányban is szerepelt, a tranzakció összegét jelölő *Amount* változó nagyságrendileg eltért a titkosított főkomponensektől. Ezt a problémát a standardizálást végző eljárás alkalmazásával hidaltam át, így biztosítva, hogy a logisztikus regressziós algoritmus ne rendeljen indokolatlanul nagy súlyt a magasabb nominális értékekhez.

```
proc stdize data=WORK.IMPORT method=std out=WORK.FRAUD_SCALED;
```

```
    var Amount;
```

```
run;
```

A skálázást követően egy adatkezelési lépés keretében a célváltozó alapján két különálló táblára bontottam a legális és a csalárd tranzakciókat, előkészítve a terepet a mintavételezéshez.

```
data WORK.CSALAS WORK.LEGALIS;
```

```
    set WORK.FRAUD_SCALED;
```

```
    if Class = 1 then output WORK.CSALAS;
```

```
    else output WORK.LEGALIS;
```

```
run;
```

A feladat legkritikusabb pontja a mesterségesen kiegyensúlyozott tanító adathalmaz létrehozása volt az alul-mintavételezési eljárás segítségével. Ennek érdekében a több, mint 280 000 legális

tranzakciót tartalmazó táblából a megfelelő SAS eljárás és az egyszerű véletlenszerű mintavétel (Simple Random Sampling) módszerének használatával kiválasztottam pontosan 492 darab megfigyelést. Ezt a mintát egyesítettem az összes regisztrált csalást tartalmazó táblával. Ezzel a módszerrel létrejött az a 984 sorból álló, tökéletesen kiegyensúlyozott munkaállomány, amelyen a prediktív modell már képes volt megbízhatóan azonosítani a visszaélések rejtett mintázatait anélkül, hogy a többségi osztály elnyomta volna azokat.

```
/* Alul-mintavételezés: 492 legális tranzakció kiválasztása és egyesítése a csalásokkal */  
proc surveyselect data=WORK.LEGALIS method=srs n=492 out=WORK.LEGALIS_SAMPLE;  
run;  
  
data WORK.MODEL_ADAT;  
    set WORK.CSALAS WORK.LEGALIS_SAMPLE;  
run;
```

A tényleges gépi tanulási fázisban a logisztikus regressziós modell felépítése következett. A modell paraméterezése során a lépésenkénti (stepwise) változószelekciós módszert alkalmaztam, amely automatikusan vizsgálta meg az összes elérhető változót, és szűrte ki a statisztikailag nem szignifikáns paramétereket, megelőzve ezzel a modell túltanulását és növelve a predikció stabilitását. A szoftver a kiegyensúlyozott mintán betanított algoritmust a kód megfelelő utasítása révén azonnal alkalmazta a teljes, majdnem háromezer soros eredeti adathalmazra is, kiszámítva minden egyes beérkező tranzakcióra a csalás bekövetkezésének matematikai valószínűségét.

```
/* Logisztikus regresszió futtatása és a teljes adathalmaz kiértékelése */  
proc logistic data=WORK.MODEL_ADAT descending;  
    model Class = Amount V1-V28 / selection=stepwise;  
    score data=WORK.FRAUD_SCALED out=WORK.SCORED_DATA;  
run;
```

6. Eredmények összefoglalása és üzleti értékelés

A mesterségesen kiegyensúlyozott mintán betanított logisztikus regressziós modell valós üzleti értékének meghatározásához a rendszert a teljes, eredeti, közel háromezer tranzakciót tartalmazó adathalmazon kellett tesztelni. A modell kiértékelése egy ötven százalékos beavatkozási küszöbérték mentén történt, ami azt jelenti, hogy a rendszer automatikusan blokkolta és csalásnak minősítette azokat a tranzakciókat, ahol a statisztikai kockázat meghaladta ezt a szintet. A futtatás eredményét egy konfúziós mátrix formájában aggregálta a szoftver, amely kristálytiszta megmutatta az informatikai megoldás számviteli és ügyfélkapcsolati hatásait.

```
/* A kiértékelés - Hány csalót fogtunk meg? */
data WORK.EVALUATION;
  set WORK.SCORED_DATA;
  /* A P_1 oszlop tartalmazza a csalás valószínűségét.
     Ha ez nagyobb mint 0.5 (50%), akkor a modell riaszt (1). */
  if P_1 > 0.5 then Predicted_Class = 1;
  else Predicted_Class = 0;
run;

title "Üzleti Eredmény: Tényleges vs. Modell által becsült (Konfúziós Mátrix)";
proc freq data=WORK.EVALUATION;
  tables Class * Predicted_Class / norow nocol nopercnt;
run;
title;
```

A modell sikerességének legfontosabb bizonyítéka a tényleges csalások azonosításának képessége, azaz a szaknyelven „érzékenységnak” nevezett mutató volt. Az adatbázisban szereplő 492 tényleges, regisztrált visszaélésből a prediktív rendszer 448 esetet sikeresen azonosított. Ez 91,1 százalékos detektálási sikerrátát jelent, ami iparági sztenderdek alapján is kiváló eredménynek számít. Számviteli szempontból ez az arány közvetlenül lefordítható megmentett tőkére és elkerült kártérítési kötelezettségekre, hiszen a bank az esetek több mint kilencvenegy százalékában képes volt megakadályozni a tolvajlást. A rendszer hálóján mindössze 44 darab kifinomult csalás csúszott át (fals negatív esetek), amely a bank számára a fennmaradó, de már maximálisan tolerálható mértékű kockázati veszteséget jelenti.

Az érem másik oldalát, vagyis az IT biztonság árát a téves riasztások (fals pozitív esetek) száma mutatja meg. A modell 8 267 esetben jelzett tévesen csalást olyan tranzakciónál, amelyek a valóságban teljesen legálisak voltak. Bár ez a szám abszolút értékben magasnak tűnhet, a több mint kétszáznyolcvanezer normál tranzakcióhoz viszonyítva ez a tévesztési arány rendkívül alacsony, jelentősen kímélve az ügyfélszolgálati kapacitásokat. A bankkártyás piacon a

pénzügyi intézetek kockázatkezelési stratégiája tudatosan vállalja ezt a kompromisszumot: üzletileg sokkal racionálisabb lépés egy automata hívással vagy SMS-sel ellenőrizni egy gyanús, de legális tranzakciót, mint hagyni, hogy az ügyfél számláját kiürítsék a kiberbűnözők. A téves riasztásokból fakadó adminisztratív többletterhelés költsége eltörpül a megakadályozott csalásokból származó pénzügyi és reputációs nyereség mellett.

Üzleti Eredmény: Tényleges vs. Modell által becsült (Konfúziós Mátrix)

The FREQ Procedure

Frequency	Table of Class by Predicted_Class		
	Predicted_Class		
Class	0	1	Total
0	276048	8267	284315
1	44	448	492
Total	276092	8715	284807

Összegzőképpen elmondható, hogy az informatika és a pénzügyi-számviteli terület összehangolt munkája, a megfelelő adat-előkészítési módszertanok (mint az alul-mintavételezés) és a prediktív gépi tanulási modellek alkalmazása elengedhetetlen a modern banki biztonságban. A felépített SAS modell bizonyította, hogy a tranzakciók rejtett, titkosított dimenzióiból is képes nagy pontossággal kiszűrni a bűnözői mintázatokat. A jövőbeli fejlesztések iránya a beavatkozási küszöbértékek dinamikus, ügyfélprofilokhoz igazodó finomhangolása lehet, amellyel a téves riasztások száma tovább csökkenthető, miközben a csalásdetektálás pontossága megmarad.

7. Irodalomjegyzék

7.1. Publikációk:

1. Advanced Rule-Based Fraud Detection Systems In Payment Processing, Arun Palanisamy, 2025.
2. Learning from imbalanced data: open challenges and future directions, Bartosz Krawczyk, 2016.
3. Special Issue on Learning from Imbalanced Data Sets, Chawla et al., 2004.
4. SMOTE: Synthetic Minority Over-sampling Technique, Chawla et al., 2002.
5. A Study of the Behavior of Several Methods for Balancing Machine Learning Training Data, Batista et al., 2004.
6. Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow, Aurélien Géron, 2019.

7.2. Internetes cikkek:

1. Payment Card Fraud Losses Approach \$34 Billion, Globe Newswire, 2025.
(<https://www.fintechfutures.com/press-releases/payment-card-fraud-losses-approach-34-billion>)

7.3. Datasets:

1. Kaggle Credit Card Fraud Detection Dataset
(<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud/data>)